

16.63

Procesamiento de Señales e Imágenes Biomédicas

Detección del onset de crisis epilépticas mediante técnicas avanzadas de procesamiento de señales y aprendizaje automático

1° cuatrimestre 2026

Fecha de entrega: 22/07/2026

Grupo 5

Llado, Maria Luján (63602) - mallado@itba.edu.ar
Kerschen Ferrari, Paz (64194) - pkerschenferrari@itba.edu.ar
Orellano, María (63201) - morellano@itba.edu.ar



Instituto Tecnológico
de Buenos Aires

Índice

Resumen.....	2
1. Introducción.....	2
1.1. Marco teórico y contextualización.....	2
1.2. Estado del arte.....	3
1.3. Trabajo previo del grupo y sus limitaciones.....	3
1.4. Objetivos del trabajo.....	4
2. Materiales y métodos.....	4
2.1. Contextualización: dataset y señales.....	4
2.2. Preprocesamiento: análisis con y sin filtrado.....	4
2.3. Detector de onset basado en CWT.....	5
2.4. Elección de la wavelet madre.....	5
2.5. Criterio de consenso multicanal y elección del umbral.....	5
2.6. Generación de etiquetas.....	5
2.7. Ventaneo y extracción de características por WPD.....	6
2.8. Normalización por animal.....	6
2.9. Clasificadores y esquema de validación.....	6
2.10. Métricas.....	6
3. Resultados.....	7
3.1. Elección del umbral y desempeño del detector.....	7
3.2. Contraste con el pipeline del trabajo previo.....	7
3.4. Detección por fragmento de los clasificadores.....	8
3.5. Naturaleza de las etiquetas.....	9
3.6. El caso de RatR3.....	9
3.7. Por qué el Random Forest supera al perceptrón multicapa.....	9
3.8. Limitaciones.....	10
4. Conclusiones.....	11
Anexo.....	12
A.1. Diagnóstico del canal L_CA1 mediante análisis de componentes independientes (ICA).....	12
A.2. Dispersión de onsets entre canales.....	12
A.3. Separación entre umbrales de crisis y de basal por MADs.....	13
A.4. Detalle por animal de las métricas de ventana (LORO): 6 vs 11 ratas.....	14
A.5. El caso de RatR3: del fallo del detector al falso positivo del clasificador.....	14
Referencias.....	15

Resumen

Se desarrolló un pipeline automático para localizar el inicio (onset) de crisis epilépticas en registros de potencial de campo local (LFP) multicanal de ratas con epilepsia del lóbulo temporal, y para clasificar ventanas de señal como ictales o interictales generalizando a animales no vistos. El detector utiliza la transformada wavelet continua (CWT) con la wavelet madre mexh, una normalización robusta en unidades de MAD calculada sobre el propio registro y un criterio de consenso multicanal sostenido. Sobre un conjunto de desarrollo de 6 animales detectó 12/12 fragmentos ictales sin falsos positivos en 12 controles; al escalar a 11 animales localizó el onset en 19 de 22 fragmentos ictales y rechazó 20 de 22 controles (especificidad 0,909, con dos falsos positivos en RatE5 y RatZ11). Las marcas de onset resultantes se usaron para etiquetar ventanas de 2 s, sobre las que se extrajeron 72 descriptores de energía relativa y entropía mediante descomposición en paquetes wavelet (db4, nivel 6). Con validación leave-one-rat-out sobre 11 animales, un Random Forest alcanzó una sensibilidad media de 0,953, especificidad 0,901 y AUC 0,977, Mientras que un perceptrón multicapa con la misma entrada y el mismo esquema de validación, no logró un patrón transferible: AUC 0,707, sensibilidad 0,453 y una inversión sistemática del ordenamiento en dos animales. Trasladado al nivel de fragmento, ese modelo colapsó (sensibilidad 0,158). Trasladada la decisión al nivel de fragmento (la unidad clínicamente relevante), el Random Forest detectó 18 de los 19 fragmentos ictales con onset válido (sensibilidad 0,947) y produjo una única falsa alarma sobre 22 controles (especificidad 0,955); la cadena completa detección-clasificación alcanzó 18/22. El trabajo documenta además dos hallazgos metodológicos: la normalización de las características contra la actividad interictal de cada animal es condición necesaria para que la validación entre sujetos funcione (AUC 0,636 a 0,957 en el conjunto de desarrollo), y el umbral de decisión debe elegirse mediante validación cruzada agrupada interna, no sobre las probabilidades del conjunto de entrenamiento.

1. Introducción

1.1. Marco teórico y contextualización

La epilepsia es un trastorno neurológico crónico caracterizado por crisis recurrentes. Aproximadamente un tercio de los pacientes presenta epilepsia refractaria, en la que las crisis no se controlan con medicación; en estos casos cobra relevancia la neuromodulación, y en particular la neuroestimulación responsiva (RNS), única terapia de lazo cerrado, que monitorea la actividad cerebral en tiempo real y estimula solo al detectar el inicio de una crisis. Su eficacia depende, por lo tanto, de identificar el onset de manera rápida y confiable [1].

El dataset se basa en el modelo de litio-pilocarpina en rata, protocolo estándar para reproducir la epilepsia del lóbulo temporal humana. Durante la fase crónica se distinguen una etapa temprana (early), de inicio focal y propagación lenta, y una tardía (late), con crisis más frecuentes y propagación prácticamente simultánea entre regiones. Como las propiedades estadísticas de la señal cambian entre etapas, todo el análisis de este trabajo se restringe a la etapa tardía.

La señal analizada es el potencial de campo local (LFP), registrado con electrodos intracraneales; frente al EEG de superficie ofrece mejor relación señal-ruido, mayor resolución espacial y conserva las frecuencias altas, incluidas las oscilaciones de alta frecuencia consideradas biomarcadores epilépticos. Según la definición del propio dataset, una crisis debe presentar actividad rítmica sostenida durante más de 30 s, un cambio claro respecto del estado interictal, propagación a múltiples canales y consenso visual de dos expertos. Estas condiciones se traducen directamente en el diseño del pipeline: la propagación fundamenta el criterio multicanal, y la duración mínima de 30 s reaparece dos veces como criterio temporal del detector (en una versión reducida) y como margen para definir las ventanas ictales e interictales, que se apoyan en que la crisis dura con seguridad más de ese tiempo.

1.2. Estado del arte

La detección automática de crisis en EEG/LFP se aborda clásicamente por dos familias. Los métodos no supervisados basados en umbral calculan un descriptor de la señal (energía en banda, entropía, disimilitud respecto de una referencia) y disparan cuando supera un umbral calibrado sobre actividad basal: son simples e interpretables, pero ese umbral no suele transferirse entre sujetos ni sesiones, ya que lo que en un animal es una desviación clara, en otro cae dentro del rango normal. Los métodos supervisados aprenden a distinguir ictal de interictal a partir de características por ventana y, correctamente validados, generalizan a registros no vistos sin recalibrar umbrales.

Dentro de las técnicas tiempo-frecuencia, la transformada wavelet ocupa un lugar central porque las crisis son eventos no estacionarios, para los que la resolución uniforme de la STFT resulta subóptima. La CWT se emplea para localizar transitorios y descargas espiga-onda, y la descomposición en paquetes wavelet (WPD) para caracterizar la energía por banda. A diferencia de la DWT, que descompone solo la rama de baja frecuencia y produce bandas diádicas cada vez más gruesas hacia las altas, la WPD descompone ambas ramas y entrega, a nivel 6, sesenta y cuatro subbandas de ancho uniforme (resolución necesaria para discriminar patrones de inicio que ocupan bandas angostas). Estas energías por banda, junto con medidas de entropía, son la entrada habitual de clasificadores supervisados (SVM, random forest, redes neuronales) en la literatura.

Un punto metodológico recurrente y subestimado es el esquema de validación: repartir aleatoriamente las ventanas de un mismo registro entre entrenamiento y prueba produce métricas optimistas, porque el solapamiento temporal y la huella del electrodo no reflejan el desempeño sobre un sujeto nuevo. La validación por sujeto leave-one-patient-out, o su equivalente leave-one-rat-out (LORO), es el esquema exigente y el que se adopta aquí. Respecto del dataset, Ni et al. (2025) [1] lo validan por inspección visual y análisis descriptivo (identificación de la SOZ y latencias, clasificación de los SOP, espectro de potencia por Welch, detección de espigas), pero no proponen un procedimiento automático de detección ni un modelo predictivo validado entre animales. Ese es el hueco que aborda este trabajo.

1.3. Trabajo previo del grupo y sus limitaciones

En la primera parte de este trabajo práctico se desarrolló un pipeline de detección sobre un único animal (RatB6) en fase tardía, basado en dos detectores de cambio complementarios aplicados a cuatro canales: un detector de disimilitud por autocorrelación (Método 1, dominio temporal, umbral mediana + 8·MAD) y un periodograma móvil con distancia L1 entre PSD normalizadas (Método 2, dominio frecuencial, umbral media + 3· σ estimado sobre un fragmento interictal de referencia). Una crisis se declaraba confirmada cuando los intervalos detectados por ambos métodos se solapan temporalmente. Sobre el fragmento analizado el criterio funcionó: ambos métodos coincidieron en el intervalo [318 s, 346 s] y el pipeline no produjo detecciones sobre un fragmento interictal independiente, lo que respaldaba su especificidad.

Ese resultado, sin embargo, tenía dos limitaciones que este trabajo aborda directamente, y que solo se hicieron visibles al ampliar el análisis.

- Un único sujeto y una única sesión. Al aplicar el pipeline sin modificaciones a otros animales del dataset, el criterio de confirmación cruzada dejó de funcionar: la referencia interictal externa y los umbrales calibrados sobre ella no se transfieren entre sesiones. En particular, sobre la propia D17 en una sesión posterior (ictal9) el Método 2 quedó saturado.
- Diagnóstico por canal. El canal L_CA1 producía detecciones sostenidas mucho después del final de la crisis. El análisis por componentes independientes mostró que se trataba de una fuente de ruido de banda ancha concentrada en ese electrodo (como se puede ver en sección A.1 del Anexo), no de actividad post-ictal genuina; el mismo canal que disparaba primero en el fragmento ictal era el que

generaba falsos positivos en los controles. Un detector que dependa de pocos canales elegidos a mano es vulnerable a este tipo de artefacto.

El presente trabajo mantiene el pipeline anterior como línea de base explícita, con su configuración original y sin modificaciones, para poder cuantificar la mejora en análisis.

1.4. Objetivos del trabajo

El objetivo general es construir y validar un pipeline de dos etapas que (i) localice automáticamente el instante de inicio de crisis en registros LFP de doce canales, sin recurrir a una referencia externa ni a umbrales ajustados por sesión, y (ii) a partir de las marcas obtenidas, entrene y evalúe clasificadores capaces de distinguir ventanas ictales de interictales en animales no vistos durante el entrenamiento.

2. Materiales y métodos

2.1. Contextualización: dataset y señales

Las señales provienen del dataset público DANDI 001044 (Ni et al., 2025) [1], [2], versión 0.240905.0159. Cada archivo se almacena en formato NWB (Neurodata Without Borders) y se accedió desde Python mediante PyNWB y la API de DANDI. Cada serie corresponde a un fragmento de 600 s de doce canales, ordenados en hemisferio derecho (R) e izquierdo (L) para las regiones SUB, DG, CA1, CA3, AMD (amígdala) y ANT (núcleo anterior del tálamo).

El criterio de selección fue el mismo para todos los animales: los dos archivos ictales de fecha más reciente (criterio de etapa tardía) tomando la primera serie de cada archivo, y el archivo non (sin crisis) de fecha más cercana a esos ictales, del que se conservaron sus dos series. Se tomaron dos fragmentos por animal y no las nueve a veintitrés crisis registradas en un mismo día porque las crisis de un mismo día son prácticamente réplicas (mismo electrodo, misma escala, misma sesión) e inflarían el tamaño de muestra con observaciones fuertemente correlacionadas. La variabilidad que interesa para la validación entre sujetos es la variabilidad entre animales. Por la misma razón se descartaron los fragmentos non antiguos (etapa early) disponibles en el dataset, que están a cincuenta u ochenta días de los ictales y corresponden a la etapa temprana: no sirven como control de la etapa tardía.

El trabajo se organizó en dos conjuntos. El conjunto de desarrollo, sobre el que se tomaron todas las decisiones de diseño (wavelet madre, umbral, esquema de normalización, forma de elegir el corte de decisión), estuvo formado por 6 animales: RatB6, RatC3, RatC16, RatD17, RatE2 y RatR2, con 12 fragmentos ictales y 12 fragmentos non. El conjunto final, sobre el que se ejecutó el pipeline ya congelado, se amplió a 11 animales, agregando RatE5, RatR3, RatR5, RatR6 y RatZ11, con 22 fragmentos ictales y 22 fragmentos non.

2.2. Preprocesamiento: análisis con y sin filtrado

No se aplicó filtrado adicional por software. En el trabajo previo se verificó experimentalmente que el filtrado de hardware descrito por los autores (pasa-altos en 0,1 Hz, notch en 50 Hz y pasa-bajos en 500 Hz) es suficiente. Se comprobó además que agregar notches en los armónicos de red degradaba ambos detectores de la Parte 1.

La única transformación aplicada fue un decimado de 1000 Hz a 500 Hz mediante filtro FIR con compensación de fase (zero_phase), lo que reduce a la mitad el costo de la CWT y de la WPD sin comprometer el análisis: la frecuencia de Nyquist resultante es de 250 Hz, por encima del límite superior de la banda más alta considerada (200 Hz).

2.3. Detector de onset basado en CWT

El detector opera en cuatro pasos por canal: se calcula la CWT y su potencia $|W(f,t)|^2$ sobre 32 escalas log-espaciadas entre 2 y 200 Hz; se promedia por banda (delta 1-4 Hz, theta-alpha 4-12 Hz, beta 13-30 Hz, gamma 30-80 Hz, alta 80-200 Hz), obteniendo $w(t)$ suavizada con media móvil de 0,25 s; cada curva se normaliza como $z(t) = (w - \text{mediana})/\text{MAD}$, calculados sobre el propio registro; y $z(t)$ final es el máximo entre las cinco bandas, para responder a un aumento relativo en cualquiera de ellas. Normalizar contra el propio registro, y no contra un fragmento externo, es la corrección central respecto de la Parte 1: como una crisis ocupa ~5 % de los 600 s del fragmento, la mediana es insensible a esa proporción de valores extremos y estima bien la actividad basal. Esto además elimina la asimetría entre señal y referencia que saturaba el Método 2 en sesiones distintas a la de calibración. Tomar el máximo entre bandas vuelve al detector agnóstico al patrón de inicio: tanto un onset LVFA (cambio concentrado en bandas altas, sin aumento de amplitud) como uno de alta amplitud en bandas bajas lo activan por igual, sin necesidad de conocer de antemano el SOP de cada animal.

2.4. Elección de la wavelet madre

Se compararon cuatro wavelets madre: mexh (sombrero mexicano), cmor1.5-1.0, cmor3.0-1.0 y cgau4, sobre los 12 fragmentos ictales del conjunto de desarrollo. El criterio de comparación no fue si detectaban la crisis, las cuatro lo hacen, sino la precisión temporal de la marca, medida como la dispersión entre los onsets de los doce canales: en fase tardía la propagación es casi simultánea, así que menor dispersión indica un borde más definido (Ver A2). Se excluyó además el cono de influencia de cada wavelet, la zona de los bordes del registro donde el soporte del filtro excede la señal disponible y los coeficientes no son confiables. El razonamiento que decide es asimétrico: una wavelet que pierde algún canal puede recuperarse bajando el umbral, mientras que la precisión temporal no se recupera con ningún ajuste posterior. Como el producto de esta etapa son marcas de onset que van a usarse para etiquetar, se privilegió la precisión temporal

2.5. Criterio de consenso multicanal y elección del umbral

Para producir una única marca por fragmento en lugar de doce marcas por canal se adoptó un criterio de consenso: el onset es el primer instante a partir del cual al menos 2 de los 12 canales superan simultáneamente el umbral $z > K$ durante al menos 5 s de forma sostenida, descartando un margen de 2 s en cada borde del registro. El requisito de duración es una versión reducida del criterio de 30 s del dataset: se exige que el cambio de régimen sea sostenido para descartar transitorios, pero se mide sobre el arranque de la crisis y no sobre su extensión total. Las espigas interictales, que duran del orden de 100 ms, no pueden satisfacerlo.

El valor de K no se fijó a ojo. Se barrió el umbral sobre los 12 ictales y los 12 controles del conjunto de desarrollo, midiendo simultáneamente sensibilidad (detectar todas las crisis) y especificidad (no disparar en ningún control), y se tomó el centro geométrico del rango en el que ambas alcanzan el 100% (Ver Sección A.3 del anexo). Se eligió el centro y no un extremo para conservar margen ante animales con propiedades algo distintas.

2.6. Generación de etiquetas

El dataset no provee la marca temporal del onset como valor numérico, sólo la etiqueta de fragmento y el consenso visual de los expertos. Las marcas producidas por el detector son, por lo tanto, el insumo que hace posible el aprendizaje supervisado por ventana. Para cada fragmento ictal con onset válido se definieron dos tramos: el tramo interictal, desde el inicio del registro hasta 30 s antes del onset, y el tramo ictal, desde 10 s hasta 30 s después del onset. Los fragmentos non aportan interictal

completo. Los dos márgenes cumplen funciones distintas. El margen previo de 30 s excluye la zona preictal, en la que la señal puede haber comenzado a cambiar sin que el detector haya disparado todavía, y evita contaminar la clase negativa. El margen posterior de 10 s excluye la zona de transición inmediatamente posterior al onset, donde la clase es ambigua; el límite de 30 s se apoya en la garantía del dataset de que las crisis duran más de ese tiempo, de modo que la ventana etiquetada como ictal está enteramente contenida en la crisis.

2.7. Ventaneo y extracción de características por WPD

Cada fragmento se recorrió con una ventana de 2 s y paso de 1 s, y cada ventana heredó la clase del tramo en el que queda completamente contenida; las ventanas que no caen enteras en ningún tramo se descartan. Sobre cada ventana y cada canal se aplicó una descomposición en paquetes wavelet con db4 a nivel 6, lo que divide el rango 0-250 Hz en 64 subbandas de aproximadamente 3,9 Hz. Las energías de los nodos se agruparon en las cinco bandas de interés y se normalizan dividiendo por la energía total de la ventana, obteniendo cinco energías relativas. Se agregó la entropía de Shannon de esa distribución, que resume si la energía está concentrada en pocas bandas (como ocurre en una oscilación rítmica) o repartida. Esto da 6 características por canal y 72 en total.

La energía relativa, en lugar de la absoluta, es deliberada: como las amplitudes difieren en más de un orden de magnitud entre animales, con potencia absoluta el clasificador aprendería a reconocer al animal antes que a la crisis y la validación entre sujetos colapsaría. La energía relativa describe la forma del espectro, lo que cambia en una crisis, y es invariante a la ganancia del electrodo.

2.8. Normalización por animal

Aún con energías relativas, cada animal conserva una huella espectral propia. Para eliminarla, cada característica se estandarizó dentro de cada animal con la media y el desvío de sus ventanas interictales: $z = (x - \mu_{\text{interictal, rata}}) / \sigma_{\text{interictal rata}}$. La huella del animal aparece en ambos términos, se cancela, y quedando la desviación de cada ventana respecto de la basal de ese mismo animal.

2.9. Clasificadores y esquema de validación

Se compararon dos modelos sobre exactamente las mismas características y el mismo esquema de validación: un Random Forest (300 árboles, class_weight balanceado, mínimo 2 muestras por hoja) y un perceptrón multicapa con dos capas ocultas de 64 y 32 neuronas, activación ReLU, optimizador Adam, regularización L2 y parada temprana, precedido de un escalado estándar.

La validación es leave-one-rat-out: se entrena con todos los animales menos uno y se predice sobre el animal excluido, rotando hasta cubrir a todos. Ninguna ventana del animal de prueba interviene en el entrenamiento.

El umbral de decisión sobre la probabilidad predicha se eligió dentro de cada iteración mediante validación cruzada agrupada (GroupKFold de 3 particiones) sobre el conjunto de entrenamiento, maximizando el índice de Youden (sensibilidad + especificidad - 1) sobre las probabilidades obtenidas fuera de muestra, y recién entonces se aplicó al animal de prueba. El conjunto de prueba nunca interviene en la elección del corte.

2.10. Métricas

Dado el fuerte desbalance entre clases, no se reporta exactitud: un clasificador que prediga siempre la clase mayoritaria alcanzaría más del 98 % de aciertos sin detectar una sola crisis. Se reportan

sensibilidad, especificidad y área bajo la curva ROC, esta última por ser independiente del corte elegido y por lo tanto la medida de la capacidad discriminativa del modelo en sí. Todas las métricas se calculan por animal y se promedian entre animales, no sobre el conjunto agregado, para que un animal con más ventanas no domine el resultado. El corte de probabilidad no se fijó en 0,5: por el desbalance, con ese valor la sensibilidad es nula. Se usa en cambio el punto de operación calibrado en la Sección 2.9.

Para trasladar las decisiones de ventana a una decisión por fragmento se adoptó el mismo criterio de evidencia sostenida que el detector de la Parte 1 (frac_min): sobre cada ventana se aplica el punto de operación del modelo (umbral de Youden calibrado por validación cruzada agrupada) y un fragmento se declara crisis si existe alguna franja de 19 s en la que al menos el 80 % de las ventanas superan ese umbral.

3. Resultados

3.1. Elección del umbral y desempeño del detector

El barrido de K sobre el conjunto de desarrollo (Figura A.3.2, del anexo) muestra una zona bien definida de operación: por debajo de 12 aparecen falsos positivos en los controles, y por encima de 30 el detector empieza a perder crisis. El rango en que sensibilidad y especificidad valen ambas 100 % es 12-30, cuyo centro geométrico es 18; se adoptó $K = 18$. Más informativo que el valor elegido es lo que revela el barrido al escalar: sobre un único animal el rango que funcionaba perfectamente era 8-150, y al incorporar seis animales se contrajo a 12-30, con el piso impuesto por la basal más ruidosa y el techo por la crisis más débil. Un umbral fijo global es, entonces, intrínsecamente frágil, y su fragilidad crece con la cantidad de animales. Esta es la justificación cuantitativa para pasar a un modelo que aprenda el límite de decisión en lugar de recibirlo fijado a mano.

Sobre el conjunto ampliado a once animales, el detector halló onset en 19 de los 22 fragmentos ictales y rechazó 20 de los 22 controles (especificidad 0,909), con dos falsas alarmas en RatE5 y RatZ11. A diferencia del conjunto de desarrollo, donde no produjo ningún falso positivo, al escalar aparecen falsas alarmas: la misma fragilidad del umbral global se manifiesta ahora también por el lado de la especificidad.

3.2. Contraste con el pipeline del trabajo previo

El detector CWT identificó la crisis en los 11 fragmentos. La tabla (Ver **Figura A.3.3**) contrasta, para cada fragmento, el intervalo del Método 1 ($M1$ rango), el onset del Método 2 ($M2$) y su intersección ($M1 \cap M2$) del pipeline previo, contra el onset del detector CWT (mexh); Δ es la diferencia entre ambos onsets ($\text{mexh} - M1 \cap M2$), y "sin conf." marca los fragmentos donde el criterio de confirmación cruzada de la Parte 1 no llegó a dispararse. Ese criterio confirmó solo 6 de los 11 fragmentos, lo que evidencia un sobreajuste de la Parte 1 que no era visible al probarse con un solo animal. Sobre los fragmentos en que ambos coinciden, la diferencia mediana entre onsets fue de $-0,4$ s, con desviación inferior a 3 s en 3 de esos 6 casos. Las dos discrepancias grandes se concentran en RatD17 ($-40,9$ s y $-29,2$ s), el mismo animal en el que ya se había documentado la falla del pipeline previo por saturación del Método 2 (Sección 1.3). En ambos casos el detector CWT dispara antes que la intersección $M1 \cap M2$: la diferencia no refleja un desacuerdo sobre el instante real de la crisis, sino la degradación del criterio de confirmación cruzada en el animal donde la Parte 1 no generalizaba.

3.3. Aprendizaje automático: 6 ratas vs 11 ratas en las ventanas

Sobre las 6 ratas, con características WPD normalizadas y validación LORO, el Random Forest generaliza bien mientras que el MLP (64,32) queda esencialmente en azar: con sólo 198 ventanas ictales frente a la cantidad de parámetros de la red, no dispone de ejemplos suficientes, y sus

probabilidades carecen de estructura al punto de dejar el umbral de corte errático o indefinido en algún animal (ver Sección A.4.1). Al extender el pipeline a las 11 ratas con datos utilizables, el Random Forest mejora, con diez de las once por encima de 0,93. Que la mejora provenga de escalar confirma que el limitante era el tamaño del conjunto y no la metodología, motivo explícito de la ampliación de 6 a 11 ratas. El MLP también mejora, lo que corrobora el diagnóstico, pero permanece muy por debajo y es inestable: en dos animales (RatD17, RatE5) el AUC cae por debajo de 0,1, es decir predicción invertida (ver Sección A.4.2). Su especificidad aparentemente alta es engañosa: surge de que casi nunca predice la clase positiva, no de buena discriminación, razón por la cual el AUC es la métrica adecuada para comparar (Tabla 1).

	6 ratas - RF	6 ratas - MLP	11 ratas- RF	11 ratas- MLP
AUC	0.960	0.517	0.977	0.707
Sensibilidad	0.884	0.042	0.953	0.453
Especificidad	0.848	0.967	0.901	0.944

Tabla 1: AUC, sensibilidad y especificidad de RF y MLP para 6 y 11 ratas (validación LORO).

La comparación de las curvas ROC (Figura A.3.4-A y A.3.5-B del anexo) hace visible el efecto del volumen de datos: al pasar de 6 a 11 animales, ambos modelos se alejan más de la diagonal, con el salto más marcado en el MLP (AUC 0,517 $\rightarrow$ 0,707). Esto confirma que la limitación principal era la cantidad de ejemplos, no la metodología, y explica que el MLP, más sensible al tamaño de muestra por su número de parámetros, sea el más beneficiado




Figura 8. Matrices de confusión por ventana (2 s) para Random Forest y MLP, normalizadas por clase real

A nivel de ventana el RF clasifica bien ambas clases, mientras que el MLP detecta menos de la mitad de las ventanas ictales y envía el resto a interictal, su alta especificidad aparente es ese sesgo hacia la clase mayoritaria, no discriminación. Además, la especificidad por ventana no es la métrica clínica final: un 10 % de error son numerosas falsas alarmas en un fragmento no de diez minutos, lo que motiva la agregación por fragmento de la Sección 3.4.

3.4. Detección por fragmento de los clasificadores

El criterio de agregación exige que la evidencia ictal se sostenga sobre una franja de 19 ventanas consecutivas (paso 1 s), que cubre los ~20 s de la ventana ictal etiquetada. Se relaja la exigencia al 80 % (frac_min = 0,8), tolerando baches puntuales sin abandonar el requisito de evidencia sostenida. Este




Figura 9. Matrices de confusión por segmento para Random Forest y MLP, normalizadas por clase real

es exactamente el criterio de la Sección 2.10, aplicado de forma idéntica a ambos modelos: lo único que varía entre Random Forest y perceptrón es el corte de ventana (índice de Youden propio de cada uno), lo que hace que la comparación sea imparcial. Random Forest declaró crisis 18 de los 19 fragmentos ictales con onset válido (sensibilidad 0,947) y produjo una falsa alarma sobre los 22 controles (especificidad 0,955). El único fragmento ictal no detectado fue RatZ11

(20191119), la crisis con menor AUC por ventana del conjunto y, por lo tanto, aquella cuya probabilidad ictal fluctúa más: no alcanza a llenar el 80 % de una franja de 19 s. El único falso positivo correspondió a un control de RatR3 (Sección 4.2). El perceptrón multicapa, bajo idéntico criterio, colapsó (sensibilidad 0,158): sus probabilidades ictales, débiles y temporalmente inconsistentes, no logran sostener evidencia a lo largo de una franja larga, y pierde crisis incluso en animales donde su AUC por ventana era aceptable.

Estas cifras corresponden a los fragmentos que llegan a la etapa de clasificación. La cifra de extremo a extremo es más conservadora: de los 22 fragmentos ictales, el detector no halló onset en 3 los dos ictales de RatR3 (sin detección) y uno de RatR2 (censurado por caer el onset dentro del margen de borde), que son falsos negativos del sistema con independencia del clasificador; de los 19 restantes, el Random Forest perdió 1 (RatZ11). La sensibilidad de la cadena completa detección-clasificación es, por lo tanto, $18/22 = 0,818$.

3.5. Naturaleza de las etiquetas

La limitación más importante, y la que condiciona todas las métricas de clasificación, es que las etiquetas por ventana no provienen del consenso de expertos sino del propio detector: como el dataset etiqueta fragmentos y no instantes, sin una marca de onset no hay forma de definir ventanas ictales, y el clasificador termina aprendiendo a reproducir las decisiones del detector.

Por eso el AUC de 0,977 del Random Forest no mide la capacidad de distinguir crisis según el criterio clínico, sino de reproducir las marcas del detector en animales no vistos. Que un modelo con solo 72 descriptores de una ventana de 2 s reproduzca esas marcas, producidas con acceso a los doce canales y al registro entero, indica una firma espectral local y consistente entre animales, pero el resultado sigue anclado a la calidad del detector. La evaluación del detector contra el etiquetado del dataset (19/22 fragmentos, Sección 3.4) sí constituye una validación contra referencia externa, y es el único punto del pipeline donde eso ocurre. Por eso conviene reportar ambos niveles por separado y no fundirlos en una única cifra de desempeño.

3.6. El caso de RatR3

RatR3 ilustra el problema anterior: el detector no halló onset en ninguno de sus dos fragmentos ictales, por lo que su sensibilidad queda indefinida y el animal sale del promedio, reportado sobre diez y no once. Contando la cadena completa sobre los 22 fragmentos, esos dos son falsos negativos del sistema. Aun así, RatR3 aporta ventanas interictales con especificidad válida (0,942, Random Forest), pero por fragmento vuelve a fallar: es el único falso positivo del Random Forest (non1), un control que el detector CWT sí rechaza. La falsa alarma es entonces exclusiva del clasificador, limitado a 72 descriptores por ventana de 2 s, frente al detector, que ve los doce canales y el registro completo (Sección A.5). RatR3 concentra así las dos formas de fallo del pipeline en fragmentos distintos.

Es, además, el único animal donde el detector no halla onset por debilidad de la señal: el tercer fragmento ictal sin marca del conjunto (RatR2-ictal1) quedó censurado por caer el onset dentro del margen de borde, una causa distinta. Este patrón se generaliza: los falsos positivos de las dos etapas no coinciden en ningún fragmento, el detector falla sobre controles de RatE5 y RatZ11 (Sección 3.1), el Random Forest sobre el de RatR3, de modo que ninguna etapa hereda los errores de la otra y no hay un control universalmente problemático.

3.7. Por qué el Random Forest supera al perceptrón multicapa

La diferencia no es un accidente de implementación ni un problema de hiperparámetros, sino estructural. El conjunto de entrenamiento efectivo contiene del orden de 170 ejemplos positivos en un espacio de 72 dimensiones, con un desbalance de 53:1. Una red densa dispone de miles de parámetros para ajustar sobre ese conjunto y encuentra fronteras que separan bien a los animales de

entrenamiento sin corresponder a una propiedad general de las crisis; los AUC por debajo de 0,5 del perceptrón en RatD17 y RatE5 confirman una inversión sistemática, no ruido: aprendió una estructura específica de los animales vistos. El Random Forest es más robusto porque sus divisiones son umbrales sobre características individuales (un desplazamiento en un animal nuevo degrada la decisión de forma gradual en lugar de invertirla) y porque el promediado sobre 300 árboles reduce la varianza, que es el error dominante con pocos ejemplos positivos. Reducir la capacidad de la red no alcanzó para cerrar la brecha, lo que apunta al volumen de ejemplos positivos como limitante de fondo.

A nivel de fragmento esta debilidad se hace concreta: el perceptrón pierde 16 de 19 crisis, incluso en animales donde su AUC por ventana era aceptable (RatC3, RatR2, RatR5, RatR6). Sus probabilidades ictales, aunque a veces correctas, son temporalmente inconsistentes y no sostienen el 80 % de una franja de 19 s. El Random Forest, sobre las mismas crisis, solo pierde RatZ11, la de menor AUC por ventana, y su único falso positivo es un control de RatR3 (Sección 4.2). Que RatZ11 sea el único fragmento perdido por ambos modelos la señala como una crisis intrínsecamente difícil, atribuible a la señal o a la marca de onset más que al clasificador.

El barrido de N confirma que el punto óptimo difiere entre modelos: el Random Forest maximiza el balance en $N = 8$ (meseta de sensibilidad 1,000 entre $N = 6$ y 8) y el perceptrón en $N = 4$. La comparación, sin embargo, se hace al mismo N para ambos: reportar cada uno en su óptimo daría una ventaja artificial. El criterio final (19 s, 80 %) es el más adverso de los evaluados, y aun así el Random Forest conserva 18/19 mientras el perceptrón cae a 3/19, lo que confirma que la brecha proviene del clasificador y no del criterio de agregación.

3.8. Limitaciones

- **Etiquetas derivadas del propio detector:** Es la limitación estructural, discutida en la Sección 4.1. La validación contra referencia externa se restringe a la clasificación de fragmentos.
- **Ausencia de un criterio de fin de crisis:** El detector localiza el onset pero no la terminación, de modo que el tramo ictal se define con duración fija (onset + 10 s a onset + 30 s) apoyándose en la garantía del dataset de que las crisis duran más de 30 s. La ventana etiquetada es por lo tanto un subconjunto temprano-medio de la crisis, y las fases tardías de las crisis largas no están representadas en el entrenamiento.
- **Normalización parcialmente circular:** La media y el desvío de cada animal se calculan sobre todas sus ventanas interictales, incluidas las de fragmentos que luego se evalúan, lo que puede favorecer artificialmente la especificidad. La variante sin circularidad normalizar cada non con el otro non del mismo animal es metodológicamente más correcta, bajó el AUC de 0,957 a 0,930 en desarrollo y no llegó a la versión final.
- **Un solo umbral global en el detector:** $K = 18$ se calibró sobre seis animales y su rango de operación se contrae al agregar sujetos; el fallo sobre RatR3 es su consecuencia directa. Una calibración por sujeto sería el siguiente paso.
- **Pérdida de información espacial:** El detector combina los doce canales en una decisión única y las características se calculan por canal pero se concatenan sin estructura, de modo que no se explota la información de latencias de propagación ni se localiza la zona de inicio de la crisis, ambos análisis presentes en el trabajo de referencia.
- **Ausencia de discriminación entre patrones de inicio:** El detector es agnóstico al SOP por diseño: una ventaja para la sensibilidad, pero impide caracterizar el tipo de onset, información con valor clínico para la que la wavelet compleja cmor1.5-1.0 sería la herramienta adecuada.
- **Desempeño del perceptrón acotado por el volumen de datos:** El bajo rendimiento del MLP no permite concluir que una arquitectura neuronal sea inadecuada para el problema, sino que no lo es

con este volumen de ejemplos positivos tratando cada ventana como observación independiente; un conjunto mayor o un modelo que explote la estructura temporal podría cambiarlo.

- **Tamaño de muestra:** Once animales, veintidós fragmentos ictales y del orden de 170 ventanas ictales independientes. Todas las cifras reportadas tienen una incertidumbre considerable, particularmente las evaluadas a nivel de fragmento, donde un solo caso mueve el resultado varios puntos porcentuales.

4. Conclusiones

Se construyó un pipeline de dos etapas que localiza el inicio de crisis epilépticas en LFP multicanal y clasifica ventanas de señal generalizando a animales no vistos. El detector, basado en la CWT con wavelet mexh y normalización robusta en unidades de MAD sobre el propio registro, detectó 12/12 fragmentos ictales sin falsos positivos sobre 12 controles en el conjunto de desarrollo, y 19/22 fragmentos con dos falsas alarmas sobre 22 controles en el conjunto final ampliado a once animales. Sus marcas coinciden dentro del segundo con las del pipeline independiente de la Parte 1 en los casos en que este último funciona.

Sobre esas etiquetas, un Random Forest con 72 descriptores de energía relativa y entropía (WPD) generalizó a animales no vistos bajo LORO (AUC 0,977), y la cadena completa detección-clasificación alcanzó 18/22. El perceptrón, con la misma entrada, no logró un patrón transferible (AUC 0,707).

Más allá de las cifras, el trabajo deja tres conclusiones metodológicas que resultaron determinantes y que no eran evidentes al comenzar. La primera es que la variabilidad entre animales domina completamente sobre la señal de crisis, si las características no se normalizan contra la actividad basal de cada sujeto la identidad del animal es predecible con exactitud 0,950 desde descriptores espectrales relativos, y sin normalización la validación entre sujetos colapsa (AUC 0,636). La segunda es que, con desbalance severo, el umbral de decisión debe elegirse mediante validación cruzada agrupada interna, elegirlo sobre las probabilidades del conjunto de entrenamiento produce un valor sobreajustado que anula la sensibilidad, y esa falla es indetectable si solo se mira el AUC. La tercera es que un umbral fijo global sobre un descriptor de la señal, por robusto que sea su cálculo, se vuelve más frágil a medida que aumenta el número de sujetos: el rango de umbrales válidos se contrajo de 8-150 con un animal a 12-30 con seis animales en el conjunto de desarrollo.

Respecto del trabajo previo, la comparación es concluyente en un sentido específico. Aquel pipeline funcionaba sobre el animal con el que fue desarrollado y se degradaba en los demás, algo que no podía detectarse evaluando un único sujeto. La ampliación a múltiples animales con validación por sujeto no mejoró los resultados anteriores: reveló que no eran generalizables. Ese, más que cualquier métrica, es el aporte principal de esta segunda parte.

Las líneas de continuación más inmediatas son sustituir el umbral global del detector por una calibración por sujeto, incorporar la variante de normalización sin circularidad ya ensayada, y explotar la estructura temporal de la señal, secuencias de ventanas en lugar de ventanas independientes, que es donde una arquitectura neuronal podría aportar algo que el Random Forest no captura.

Anexo

A.1. Diagnóstico del canal L_CA1 mediante análisis de componentes independientes (ICA)

Reparto de cada componente entre los 4 canales
(fracción del peso de la componente que cae en cada canal)

	IC0	IC1	IC2	IC3
R_AMD	0.22	0.02	0.23	0.59
R_CA1	0.19	0.05	0.51	0.08
L_AMD	0.35	0.03	0.14	0.01
L_CA1	0.24	0.90	0.13	0.32 ←

→ La componente IC1 concentra 90% de su peso en L_CA1.
Interpretación: ICA AISLÓ el ruido de L_CA1 como fuente propia.
→ se puede reconstruir sin esa componente para 'limpiar' el canal.

Efecto de remover IC1 sobre cada canal
(varianza removida = $1 - \text{var}(\text{limpio})/\text{var}(\text{original})$)

R_AMD : varianza removida = 0.3%
R_CA1 : varianza removida = 2.2%
L_AMD : varianza removida = 1.3%
L_CA1 : varianza removida = 93.1% ← objetivo

Figura A.1.1. Reparto de cada componente independiente entre los cuatro canales. IC1 concentra el 90 % de su peso en L_CA1.

Figura A.1.2. Varianza removida por canal al reconstruir sin IC1: 93,1 % en L_CA1, $\leq 2,2$ % en el resto, confirma que IC1 es ruido local de ese electrodo.




Figura A.1.3. L_CA1 antes (rojo) y después (verde) de remover IC1: la crisis (~300–350 s) persiste, el ruido de fondo desaparece. Abajo, la componente removida (gris) es difusa y sin estructura ictal.

A.2. Dispersión de onsets entre canales




Figura A.2.1. Dispersión de onsets entre canales por wavelet madre mexh: mediana más baja (2,98 s).




Figura A.2.2. Primeros 10 s, canal R_AMD: señal cruda (arriba) y $z(t)$ con umbral (abajo). El pico de z en la zona del COI de mexh (1 s, sombreado oscuro) no está respaldado por la señal cruda, lo que justifica ampliar el margen de borde a 2 s (sombreado claro).

A.3. Separación entre umbrales de crisis y de basal por MADs




Figura A.3.1. $z(t)$ del canal R_AMD: ictal (arriba) vs non (abajo) de RatB6, con referencias en 8, 50, 200 y 1000 MADs. Umbrales ≥ 200 dejan de detectar la crisis, lo que acota el rango válido de K (Sección 2.5).

v1 CLÁSICO (M1nM2) vs DETECTOR WAVELET (mexh)					
K_MAD	detecta	FP	sens	espec	veredicto
2	11/11	10/12	100%	17%	✗ FP: B6_2023_7_23-n, B6_2023_7_23-n
3	11/11	5/12	100%	58%	✗ FP: B6_2023_7_23-n, C16_2023_11_1-
5	11/11	3/12	100%	75%	✗ FP: B6_2023_7_23-n, C16_2023_11_1-
8	11/11	1/12	100%	92%	✗ FP: R2_2022_5_1-no
12	11/11	0/12	100%	100%	✓ PERFECTO
20	11/11	0/12	100%	100%	✓ PERFECTO
30	11/11	0/12	100%	100%	✓ PERFECTO
50	10/11	0/12	91%	100%	✗ pierde: C3_2023_10_2
80	7/11	0/12	64%	100%	✗ pierde: C16_2023_10_, C16_2023_10_, C3_2023
120	6/11	0/12	55%	100%	✗ pierde: C16_2023_10_, C16_2023_10_, C3_2023
200	6/11	0/12	55%	100%	✗ pierde: C16_2023_10_, C16_2023_10_, C3_2023
350	3/11	0/12	27%	100%	✗ pierde: C16_2023_10_, E2_2019_7_3-, E2_2019
600	0/11	0/12	0%	100%	✗ pierde: C16_2023_10_, R2_2022_4_30, E2_2019
1000	0/11	0/12	0%	100%	✗ pierde: C16_2023_10_, R2_2022_4_30, E2_2019

fragmento	M1 rango	M2	M1nM2	mexh	Δ
B6_2023_7_24-ictal1	315-346	318s	318.0s	317.6s	-0.4s
B6_2023_7_25-ictal1	291-351	296s	296.0s	298.2s	+2.2s
C16_2023_10_30-ictal1	348-354	281s	sin conf.	283.1s	-
C16_2023_10_31-ictal1	272-468	273s	273.0s	272.7s	-0.3s
C3_2023_10_23-ictal1	319-446	321s	321.0s	325.9s	+4.9s
C3_2023_10_24-ictal1	345-389	-	sin conf.	349.1s	-
D17_2024_1_4-ictal1	301-464	346s	346.0s	305.1s	-40.9s
D17_2024_1_5-ictal1	268-416	303s	303.0s	273.8s	-29.2s
E2_2019_7_3-ictal1	327-542	-	sin conf.	334.6s	-
E2_2019_7_7-ictal1	267-482	-	sin conf.	274.6s	-
R2_2022_4_30-ictal1	260-487	-	sin conf.	273.4s	-

v1 (M1nM2) confirma : 6/11
mexh detecta : 11/11
 Δ mediano = -0.4s | $|\Delta| < 3s$ en 3/6

Figura A.3.2: Barrido del umbral K

Figura A.3.3 Comparación del detector CWT (mexh) con el criterio $M1 \cap M2$

A.3.4 y A.3.5 Aprendizaje automático: 6 ratas vs 11 ratas en las ventanas




Figura A.3.4-A: ROC de validación entre animales (LORO, 6 ratas, WPD). RF AUC=0,938 vs MLP AUC=0,495.




Figura A.3.5-B: ROC de validación entre animales (LORO, 11 ratas, WPD). RF AUC=0,977 vs MLP AUC=0,653.


A.4. Detalle por animal de las métricas de ventana (LORO): 6 vs 11 ratas

MODELO 1 - RANDOM FOREST (WPD)					
Random Forest	rata test	corte	sens	espec	AUC
RatB6	0.016	1.000	0.812	0.983	
RatC16	0.022	1.000	0.842	1.000	
RatC3	0.020	0.472	0.950	0.869	
RatD17	0.026	0.833	0.911	0.962	
RatE2	0.020	1.000	0.714	0.966	
RatR2	0.016	1.000	0.858	0.980	
MEDIA		0.884	0.848	0.960	
MODELO 2 - MLP (WPD)					
MLP	rata test	corte	sens	espec	AUC
RatB6	0.114	0.194	0.998	0.831	
RatC16	0.037	0.056	0.989	0.524	
RatC3	inf	0.000	1.000	0.690	
RatD17	0.009	0.000	0.869	0.041	
RatE2	0.011	0.000	0.950	0.470	
RatR2	0.037	0.000	0.994	0.546	
MEDIA		0.042	0.967	0.517	
MODELO 1 - RANDOM FOREST					
Random Forest	rata test	corte	sens	espec	AUC
RatB6	0.026	1.000	0.885	0.992	
RatC16	0.029	1.000	0.893	0.998	
RatC3	0.023	0.944	0.903	0.976	
RatD17	0.023	0.917	0.891	0.967	
RatE2	0.029	1.000	0.888	0.998	
RatE5	0.027	1.000	0.801	0.935	
RatR2	0.029	1.000	0.908	0.981	
RatR3	0.027	nan	0.942	nan	
RatR5	0.023	0.944	0.961	0.994	
RatR6	0.023	1.000	0.925	0.992	
RatZ11	0.033	0.722	0.910	0.939	
MEDIA		0.953	0.901	0.977	
MODELO 2 - MLP (64,32)					
MLP	rata test	corte	sens	espec	AUC
RatB6	0.011	0.611	0.988	0.961	
RatC16	0.003	0.389	0.957	0.776	
RatC3	0.006	0.528	0.952	0.809	
RatD17	0.015	0.000	0.933	0.072	
RatE2	0.008	0.000	0.994	0.682	
RatE5	0.003	0.000	0.878	0.011	
RatR2	0.011	0.778	0.994	0.963	
RatR3	0.008	nan	0.987	nan	
RatR5	0.009	0.750	0.991	0.989	
RatR6	0.002	0.972	0.744	0.938	
RatZ11	0.004	0.500	0.963	0.873	
MEDIA		0.453	0.944	0.787	


A.4.1. Análisis con 6 ratas

A.4.2. Análisis con 11 ratas

A.5. El caso de RatR3: del fallo del detector al falso positivo del clasificador



A.5.1. RatR3: LFP y $|z(t)|$ del fragmento ictal (izq., sin onset) y non (der.), canal R_AMD. El descriptor supera $K=18$ gran parte del registro en ambos casos, sin contraste ictal/interictal claro, por eso el detector no halló onset.



A.5.2. RatR3, fragmento non R3_2022_3_16-non1: probabilidad ictal por ventana del Random Forest. Una franja sostenida entre ~548-567 s supera el corte de Youden durante 45 de 599 ventanas, cumpliendo el criterio de 19 s/80 % y disparando el único falso positivo del modelo (Sección 3.4).

Referencias

- [1] Ni, H., Yang, Y., Zhang, F., Sun, Y., Zheng, Y., Zhu, J. & Xu, K. (2025). Dataset of long-term multi-site LFP activity with spontaneous chronic seizures in temporal lobe epilepsy rats. Scientific Data, 12, 709. <https://doi.org/10.1038/s41597-025-05023-7>
- [2] Ni, H. et al. (2025). Long-term multi-site LFP activity with spontaneous chronic seizures in temporal lobe epilepsy rats [Dataset]. DANDI Archive, Dandiset 001044. <https://dandiarchive.org/dandiset/001044>
- [3] Neurodata Without Borders (NWB) y PyNWB - formato estándar y librería de Python para acceso a datos de neurofisiología. <https://www.nwb.org/> ; <https://pynwb.readthedocs.io/>
- [4] Lladó, M. L., Kerschen Ferrari, P. & Orellano, M. (2026). PSIB2026Q1-TPS-Grupo5-KerschenOrellanoLlado. [<https://github.com/lujillado/PSIB2026Q1-TPS-Grupo5-KerschenOrellanoLlado>]
- [5] Lladó, M. L., Kerschen Ferrari, P. & Orellano, M. (2026). PSIB2026Q1-FINAL-Grupo5-KerschenOrellanoLlado. [<https://github.com/lujillado/PSIB2026Q1-FINAL-Grupo5-KerschenOrellanoLlado>]